

Recuperação de Padrões na Valoração Textual de Redações

Eugênio Cunha¹, Dr. Marco Túlio Alves Nolasco Rodrigues¹

¹Universidade de Itaúna (UIT)

Caixa Postal 100 – 35.680-142 – Itaúna – MG – Brasil

{genio.py, tulio.rodrigues}@gmail.com

Abstract. *Nowadays, there is an intense amount of essays being produced and evaluated in entrance exams, competitions and exams. Unlike the manuals, which process and evaluate the essays manually, this work addresses an automatic way, through machine learning, capable of generalizing, learning and extracting standards from writing based on the labeled content. The method needs little human intervention and allows the valuation of large amounts of texts. This job is based on the problem of manual assessment of competences required in a essay-argumentative writing text with diverse themes social, scientific, cultural or political. Given a corpus of the main objective is to induce a model to classify the required by writing an evaluation note on the text. Embasado in the main metrics of analysis of the classifiers cited in the literature of machine learning, the solution proposed in this work was shown to be useful and useful for use in issues involving text valuation manual by trained professionals.*

Resumo. *Nos dias atuais, há uma quantidade intensa de redações sendo produzida e avaliada em vestibulares, concursos e exames. Diferentemente dos métodos existentes, que processam e avaliam as redações de maneira manual, este trabalho aborda uma forma automática, por meio de aprendizagem de máquina, capaz de generalizar, aprender e extrair padrões das classes de redações com base no conteúdo rotulado. O método precisa de pouca intervenção humana e permite a valoração de grandes quantidades de textos. Este trabalho fundamenta-se no problema de avaliação manual das competências exigidas em um texto de redação do tipo dissertativo-argumentativo com temas diversificados de ordem social, científica, cultural ou política. Dado um “corpus” de redações o objetivo principal é induzir um modelo a classificar as competências exigidas compondo uma nota avaliativa sobre o texto. Embasado nas principais métricas de análise dos classificadores citados na literatura de aprendizado de máquina, a solução proposta neste trabalho demonstrou ser útil e propícia a ser utilizada em problemas que envolva a valoração de texto manual por profissionais capacitados.*

1. Introdução

O desenvolvimento de uma redação é uma atividade prática presente na cultura civilizada desde a invenção da escrita. Na década de 70 iniciou-se processo de redemocratização que consequentemente restituiu a palavra ao estudante. O decreto 79.298, de 24 de Fevereiro de 1977 definiu a volta da redação à escola pela “inclusão obrigatória da prova ou questão de redação em língua portuguesa” nos concursos e vestibulares (Art. 1º, alínea d) (LARA, 1994).

A redação é aplicada no ENEM desde a primeira edição 1998, hoje o maior exame do Brasil, que na edição de 2016 contou com 8.627.195 escritos confirmados, e a participação direta de 11.360 profissionais externos na correção de 5.825.134 redações. Com o advento do ENEM ser um requisito para o processo seletivo de acesso a inúmeras universidades públicas (SISU, 2017) e a importantes programas de governo (CSF, 2017), este número tem aumentado incessantemente. Segundo o edital do ENEM 2016, cada redação foi avaliada por, pelo menos, dois avaliadores, de forma independente, uma estimativa mínima de 11.650.268 avaliações manuais das competências exigidas em um texto de redação pelo ENEM (INEP, 2016). Devido à grande quantidade de redações produzidas, torna-se humanamente difícil e caro organizar e avaliar as competências de uma redação manualmente.

Com o processamento computacional mais barato e poderoso, a crescente variedade e volume de dados disponíveis, e o armazenamento de dados de forma acessível, o Aprendizado de Máquina está no centro de muitos avanços tecnológicos, alcançando áreas antes exclusivas de seres humanos. Os carros autônomos do Google são o exemplo de uma atividade antes exclusivamente humana e hoje exercida e aperfeiçoada por algoritmos de Aprendizado de Máquina (WAYMO, 2017). O Aprendizado de Máquina está presente na nossa vida cotidiana como, resultados de pesquisa web, análise de sentimento baseado em texto e na detecção de fraudes em operações com cartões de crédito entre outras aplicações (BATISTA et al., 1999).

A avaliação de redações automática pode ser realizada utilizando sistemas especialistas ou algoritmos de Aprendizado de Máquina. A primeira hipótese dependente essencialmente da presença de especialistas que detem o conhecimento sobre o domínio do problema para desenvolver um conjunto de regras. O sistema especialista deve ser capaz de tomar suas decisões, ou seja, as regras são disparadas para atingir determinada decisão (NEGNEVITSKY, 2005). Entretanto regras desenvolvidas manualmente tem um processo de manutenção e atualização complexo, o que torna mais difícil a sua utilização em diferentes domínios do problema proposto.

O uso de algoritmos de Aprendizado de Máquina para valoração de redações é uma alternativa ao sistema especialista, exige um menor esforço humano com a abstração simples de extrair padrões ou características, aprender e generalizar. Dados os benefícios, a hipótese deste artigo é que um algoritmo de Aprendizado de Máquina pode ser útil e propício a ser utilizada em problemas que envolva a valoração de texto manual por profissionais capacitados.

Além disso, para avaliar e validar a hipótese, o método de construção do conhecimento deste trabalho terá como fundamento o problema de recuperação de padrões na valoração textual. Dado um “corpus” de redações o objetivo principal é induzir um modelo a classificar as competências exigidas compondo uma nota avaliativa sobre a redação. O presente estudo com base na proposta do problema descrito contribuirá na área do Aprendizado de Máquina e diretamente no processo de valoração de um texto em prosa do tipo dissertativo-argumentativo.

2. Trabalhos Relacionados

Este tópico é destinado a listar uma sequência de trabalhos científicos nas áreas abordadas por este estudo com o objetivo de adquirir conhecimento para a elaboração do mesmo.

Segundo [Silva e Carvalho \(2017\)](#), à prova de redação do ENEM é avaliada levando em conta uma matriz de referência do [INEP \(2016\)](#). Essa matriz, foi desenvolvida com a colaboração de especialistas, com o objetivo de operacionalizar o exame. A matriz apresenta cinco competências, para cada competência expressa para redação existem níveis de conhecimento associados de 0 a 5. [Braga \(2015\)](#) explica em seu trabalho, que em um texto de redação, o candidato defenderá uma opinião a respeito do tema proposto, de forma coerente e coesa, embasado em argumentos consistentes. O texto será redigido respeitando a escrita formal da Língua Portuguesa. Ao fim, o candidato elabora uma proposta de intervenção social para o problema apresentado no desenvolvimento do texto que respeite os direitos humanos.

Em seu estudo [Monard e Baranauskas \(2003\)](#) cita: “A indução é a forma de inferência lógica que permite obter conclusões genéricas sobre um conjunto particular de exemplos.” Na indução, um conceito é aprendido efetuando-se inferência indutiva sobre os exemplos apresentados. O aprendizado indutivo pode ser dividido em supervisionado e não-supervisionado como ilustrada a Figura 1. No aprendizado não-supervisionado, o algoritmo de aprendizado analisa os exemplos fornecidos e tenta determinar se alguns deles podem ser agrupados de alguma maneira, formando *clusters* ou agrupamentos. Já no aprendizado supervisionado é fornecido ao algoritmo de aprendizado um conjunto de exemplos de treinamento para os quais o rótulo da classe associada é conhecido.

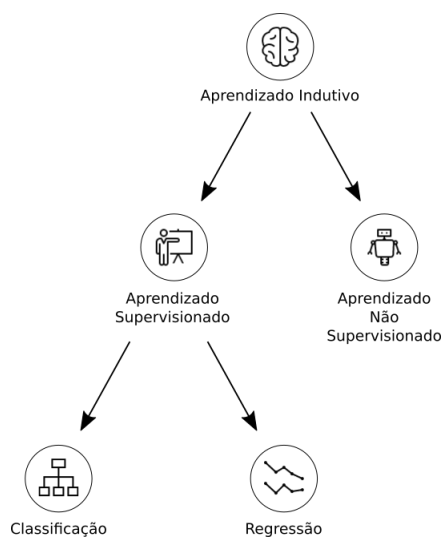


Figura 1. Árvore hierárquica do aprendizado indutivo, a qual é dividida em algoritmos supervisionado e não-supervisionado.

Classificadores são utilizados para a predição de classes de objetos e pode ser dita como o processo de generalização dos dados a partir de diferentes instâncias. Existe uma tendência de se referir a problemas com uma resposta quantitativas como problemas de regressão e aqueles com uma resposta qualitativa como problemas de classificação. Dado um conjunto de exemplos como ilustrado na Figura 2, os classificadores devem encontrar uma função geral capaz de prever adequadamente as saídas para novos exemplos, após o treinamento, o classificador é avaliado e se necessário o processo de classificação pode ser ajustado usando o conhecimento sobre o domínio do problema para escolher os dados de entrada ao algoritmo de aprendizado de acordo com [Motta \(2016\)](#).

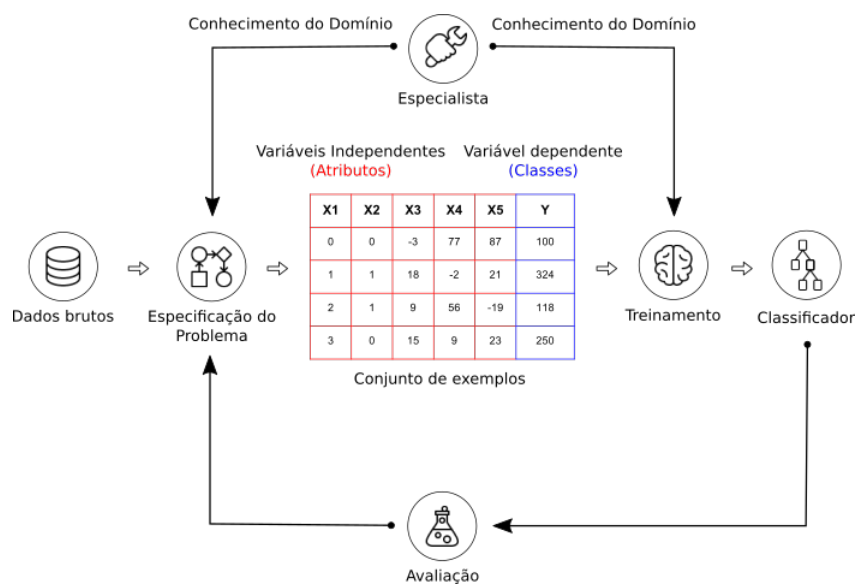


Figura 2. Fluxo do processo de classificação, o modelo encontra uma função geral capaz de prever as saídas, a especificação do problema pode ser reajustada com o conhecimento do domínio para obter um melhor resultado.

Diversas ferramentas disponíveis para exploração de dados dispõem de soluções para o processamento e a análise das informações de forma ágil e simples. Em uma análise comparativa [Boscarioli, Viterbo e Teixeira \(2014\)](#) demonstra que não existe uma única ferramenta com características melhores para todas as aplicações em mineração de dados. Em um estudo que comparou quatro ferramentas (KMINE, *Orange*, Tanagra, Weka), todas de código aberto, gratuitas e muito utilizadas na pesquisa e na academia, [Wahbeh et al. \(2011\)](#) concluiu que a ferramenta Weka apresentou o melhor desempenho, seguido pelo *Orange*, e, depois, pelo KMINE e Tanagra. De acordo com ([DEMŠAR et al., 2013](#)), a ferramenta *Orange* na atual versão 3.5 desenvolvida pelo laboratório de Inteligência Artificial da Faculdade de Computação e Ciência da Informação da Universidade de *Ljubljana* na *Eslovênia* sob a licença GPL, possui uma interface gráfica denominada *Orange Canvas*. Por meio de sua interface gráfica denominada *Orange Canvas*, é possível conectar e interligar os objetos montando um fluxo de trabalho para o desenvolvimento de modelos de classificação, incluindo *Adaboost*, *Naive Bayes*, Regras de Decisão, Árvore de Decisão, etc..

No processo de mineração de dados, segundo [Matsubara, Martins e Monard \(2003\)](#), na etapa de pré-processamento de textos, um dos métodos geralmente adotado é a representação usando a abordagem “bag-of-words”, uma das representações estruturadas mais simples, que utiliza técnicas de redução do termo ao seu radical e remoção de termos irrelevantes. Cada documento é representado como um vetor de palavras que ocorrem no documento, especificamente uma tabela atributo-valor.

Segundo a pesquisa de [BRITO \(2017\)](#), o classificador Naive Bayes é um progenitor probabilístico para textos, está entre um dos mais utilizados no Aprendizado de Máquina, devido a seu comportamento simplista que traz bons resultados em muitos casos. Baseado no Teorema de Bayes, criado por Thomas Bayes no século XVIII, este classificador é eleito o mais eficiente na precisão e rotulação de novas amostras de acordo com o trabalho

de [Chakrabarti \(2002\)](#). Objetivo da classificação Naive Bayes é encontrar a melhor classe, uma característica atraente desse classificador.

Um dos algoritmos mais famoso e utilizado no Aprendizado de Máquina é *AdaBoost* ou *Adaptive Boosting* derivado do *Boosting*, uma técnica de Aprendizado de Máquina que usa diversos classificadores fracos com a finalidade de aumentar a acurácia geral. Segundo [Reis \(2015\)](#), o seu sucesso deve-se ao mérito de conseguir adaptar-se aos classificadores base. Neste algoritmo, classificadores são gerados de forma a ajudar os exemplos incorretamente classificados pelos classificadores antecedentes. Este algoritmo aumenta os pesos dos exemplos em que os classificadores anteriores cometeram erros.

3. Metodologia

Para concluir com êxito o desenvolvimento deste trabalho e consequentemente os objetivos propostos, o método utilizado para solução do problema é composto das seguintes etapas sequenciais:

3.1. Coleta de textos

Para as avaliações experimentais e análises realizadas neste estudo foram coletadas redações de dois diferentes projetos que estimulam o estudante a treinar a produção de textos do gênero dissertativo-argumentativo, sugerindo um tema, avaliando e publicando ([ESCOLA, 2017](#)) e ([UOL, 2017](#)).

Nos dias atuais consegue-se facilmente coletar textos de páginas web, para esta tarefa, foi necessário criar um *crawler*. Existem diversas formas de implementar um *crawler*, dentre elas, uma muito utilizada é o *Scrapy*, utilizado neste trabalho ([SCRAPY, 2017](#)). O uso de um *crawler*, permite explorar a estrutura de grafo da *web*, navegar de uma página para outra identificando as *tags* HTML que contém os dados necessários para compilar um *dataset*. A figura 3 ilustra a etapa em que o *crawler* navega entre as páginas HTML, filtra as *tags*, coleta e armazena os dados em um *dataset*.




Figura 3. O *crawler*, navega entre as páginas HTML do banco de redações de forma metódica e automatizada indexando textos que posteriormente serão filtrados, coletados e armazenados.

3.2. Balanceamento de dados

Em muitos domínios, os conjuntos de dados são naturalmente desbalanceados. Dados desbalanceados representam o domínios onde qualquer classes de um grupo de dados está

representado por um amplo número de exemplos, enquanto as demais classes são representadas por poucos exemplos. Abordagens a nível de dados equilibram a distribuição das classes no conjunto de dados, usar técnicas como *undersampling* e *oversampling* resolvem o problema do desbalanceamento de acordo com o estudo de [Ferreira, Dosciatti e Paraiso \(2014\)](#). A técnica *oversampling* replica de forma aleatória exemplos da classe minoritária, enquanto a técnica *undersampling* utilizada neste estudo, elimina aleatoriamente exemplos da classe majoritária. Além disso, [Machado \(2009\)](#) em seu estudo indica o uso das técnicas de limpeza de dados a fim de eliminar os exemplos ruidosos e *limítrofes*, respectivamente (*class-label noise*, *borderlines*). A figura 4 ilustra a etapa onde os dados naturalmente desbalanceados são submetidos a técnica *undersampling* e limpeza de dados, resultando um *dataset* menor e balanceado.

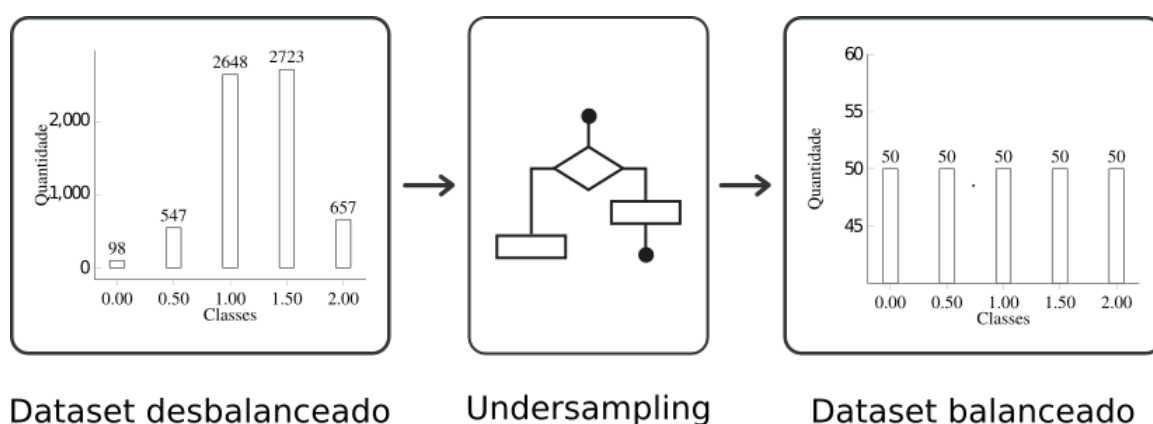


Figura 4. O *dataset* desbalanceado é submetido a técnica *undersampling* que gera um *dataset* menor e balanceado.

3.3. Pré-processamento, inferência indutiva e métricas de desempenho

A ferramenta de *Data Mining Orange* utilizada neste estudo, permite o pré-processamento de dados, divisão do *dataset* para treinamento e teste, bem como, a inferência indutiva simultânea dos classificadores *Adaboost* e *Naive Bayes*. Os resultados das métricas de desempenho obtidos podem ser plotados para avaliação e comparação dos classificadores ([WAHBEH et al., 2011](#)).

No fluxo de trabalho (*workflow*) da ferramenta *Orange* a indução dos classificadores normalmente ocorre de forma automática. A aplicação monitora o domínio do problema desenvolvido em seu *workflow*, detecta alterações e dispara o gatilho que induz os classificadores automaticamente. Isso permite facilmente realizar alterações e interpretar os resultados da inferência indutiva dos classificadores segundo a documentação, *Orange* (2017).

A figura 5 ilustra as etapas necessárias para pré-processamento, indução e testes dos algoritmos classificadores. Devido à natureza textual não estruturada dos textos contidos no *dataset*, no primeiro passo os documentos armazenados necessitam de um pré-processamento. Cada sentença do texto é separada em *tokens* para transformar esses dados não estruturados em um formato estruturado, especificamente uma tabela atributo-valor, denominada *bag-of-words*. Nesta abordagem, palavras pouco significativas como artigos, preposições e conjunções que pouco caracterizam o texto podem ser ignoradas

com uma ou mais listas de *stopwords*. Segundo Matsubara, Martins e Monard (2003), este passo é importante, visto que a representação desses textos tem uma influência fundamental no resultado da indução dos algoritmos de Aprendizado de Máquina. No segundo passo é necessário definir os parâmetros da inferência indutiva de cada algoritmo e induzir os modelos classificadores *Adaboost* e *Naive Bayes*. O terceiro e último passo, o resultado da inferência dos classificadores são avaliados com as principais métricas de análise de classificadores citadas na literatura de Aprendizado de Máquina. Os passos dois e três são repetidos até que um dos classificadores apresente resultados relevantes ao estudo.

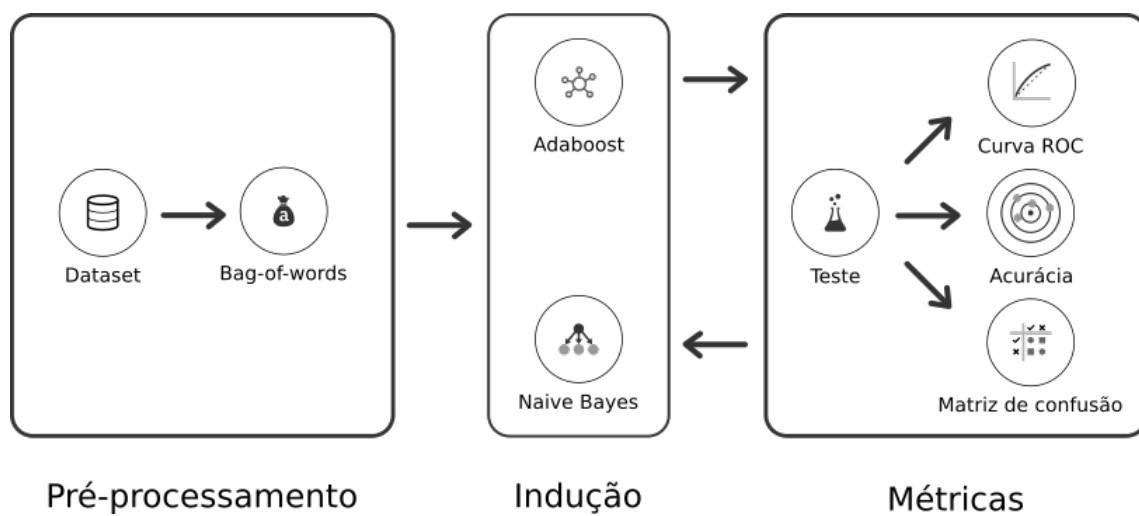


Figura 5. O *dataset* balanceado é submetido a técnica *bag-of-words* no pré-processamento, resultando em uma estrutura de atributo-valor utilizada na inferência indutiva dos classificadores, por fim, os modelos induzidos são avaliados por métricas de desempenho.

3.4. Validação cruzada

Para avaliar e validar a hipótese proposta foi adotada a metodologia de validação cruzada, já prevista no próprio ferramenta *Orange*. O estudo de Tavares, Lopes e Lima (2007) explica que esta abordagem consiste em fracionar o *dataset* em N partes (*folds*). Destas, $N-1$ partes são aplicadas na inferência indutiva e uma amostra é utilizada como base de testes. O método é repetido N vezes, de forma que cada fração seja utilizada apenas uma vez como conjunto de testes. por fim, é calculada pela média dos resultados atingidos em cada ciclo, obtendo-se assim uma estimativa da qualidade da inferência induzida, o que permite análises estatísticas. A Figura 6 ilustra o fracionamento do *dataset* em N partes, da qual, uma amostra é separada para testes e as demais para inferência indutiva, ao fim, é calculada a média dos resultados obtidos de cada métrica de desempenho.

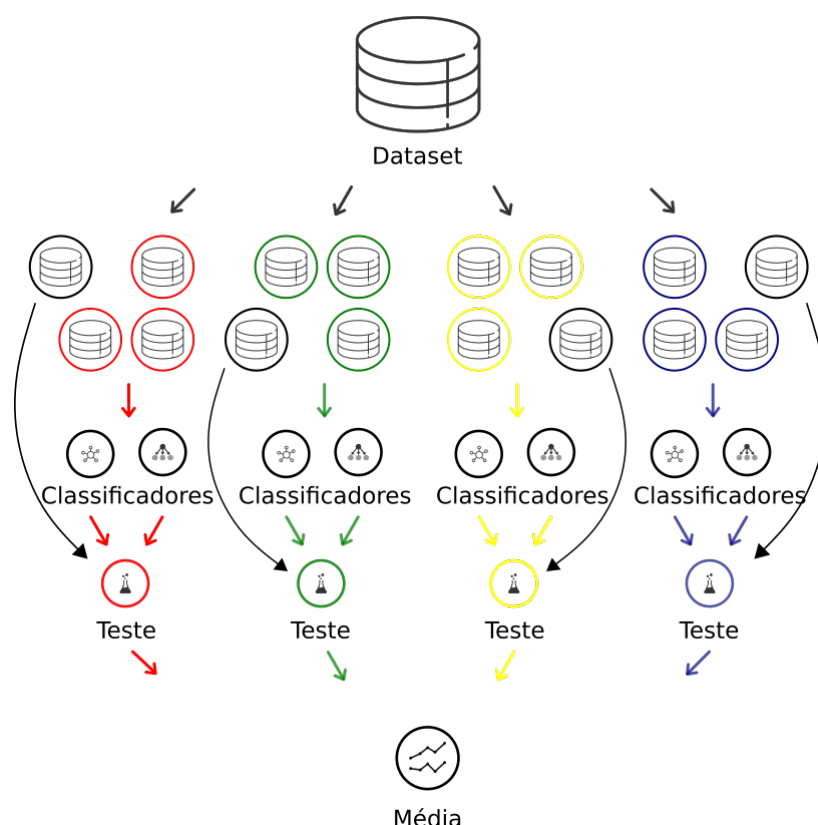


Figura 6. O *dataset* balanceado é fracionados em N partes, sendo uma parte separada para testes e as demais utilizada na indução dos classificadores, por fim, é calculada a média dos resultados obtidos.

4. Resultados

Este tópico é dedicado a apresentar os resultados, adversidades e contribuições alcançadas durante o desenvolvimento do estudo referente ao problema proposto. Por fim, são apresentadas considerações sobre as limitações ocorridas no desenvolvimento deste trabalho. Nos resultados do problema proposto, este estudo utilizou as principais métricas da literatura para análise de desempenho dos classificadores.

4.1. Configuração do experimento

Dada a matriz de referência do [INEP \(2016\)](#), a competência III foi selecionada aleatoriamente como o alvo da inferência indutiva dos classificadores.

4.2. Disposição das classes no *dataset*

Dada as 6.663 redações coletadas originalmente, com temas diversificados que passaram em um processo de avaliação manual com diferentes avaliadores, a aplicação dos métodos de balanceamento e limpeza de dados, filtrou um segundo *dataset*, dispondo de 690 redações. O Gráfico 7 demonstra a disposição das classes distintas (0.00, 0.50, 1.00, 1.50, 2.00) sobre as cinco competências exigidas.




Figura 7. Distribuição das classes sobre a competência III de 690 redações no *dataset* balanceado, cada classe da competência III possui uma amostragem de 138 redações.

A quantidade de exemplos da competência III obtidos no *dataset* pode apresentar-se de uma certa forma modesta, entretanto normalmente é suficientemente para produzir resultados relevantes na validação cruzada.

4.3. Resultado da inferência indutiva

A inferência indutiva dos classificadores *Adaboost* e *Naive Bayes*, utilizando o *dataset* originou o Gráfico 8, onde está delineado os resultados da *acurácia* de cada classe distinta sobre domínio do problema. Com isso, nota-se que em relação ao algoritmo *Adaboost*, a indução do *Naive Bayes* proveu uma melhor *acurácia* na maior parte das classes.




Figura 8. Sobreposição dos resultados de *acurácia* na inferência indutiva dos algoritmos *Adaboost* e *Naive Bayes*.

No Gráfico 9 é apresentado os resultados referentes ao ponto de corte da curva ROC correspondente a cada classe distinta. Através deste ponto avalia-se que o poder de discriminação das classes do algoritmo *Naive Bayes* foi superior em relação ao *Adaboost*.




Figura 9. Sobreposição dos resultados da curva ROC na inferência indutiva dos algoritmos *Adaboost* e *Naive Bayes*.

A matriz de confusão ou tabela de contingência é uma ferramenta importante para avaliar os resultados da predição, facilita visualmente o entendimento e reage aos efeitos de predições falsas.

		Naive Bayes					
		0.00	0.50	1.00	1.50	2.00	Σ
Atual	0.00	92	23	9	6	8	138
	0.50	20	83	28	4	3	138
	1.00	24	18	68	19	9	138
	1.50	19	5	12	75	27	138
	2.00	19	6	7	52	54	138
	Σ	172	135	124	156	101	690

Tabela 1. Matriz de confusão resultante da indução do classificador Naive Bayes.

		Adaboost					
		0.00	0.50	1.00	1.50	2.00	Σ
Atual	0.00	83	10	27	11	7	138
	0.50	17	74	38	8	1	138
	1.00	10	19	77	19	13	138
	1.50	3	2	21	74	38	138
	2.00	12	3	12	50	61	138
	Σ	125	108	175	162	120	690

Tabela 2. Matriz de confusão resultante da indução do classificador Adaboost.

A análise da matriz na Tabela 1 e 2 respectivamente dos algoritmos *Naive Bayes* e *Adaboost* foi fundamental para a avaliação dos classificadores. Em ambos classificadores o resultado poderia ser melhor, se caso o padrão encontrado dentro do texto pudessem ser mensurado com maior representatividade obtendo uma melhor separação entre as valorações de cada competência, entretanto este resultado corrobora com a hipótese proposta para este estudo. De acordo ainda com a análise da matriz de confusão apresentada nas Tabelas 1 e 2, o número de predições corretas do classificador *Naive Bayes* apresentou um resultado melhor em relação ao algoritmo *Adaboost*.

5. Discussão

Primeiramente, como citado na Seção 2 foi utilizada a ferramenta de *Data Mining Orange*, devido a sua boa classificação quanto as principais utilizadas no meio acadêmico, a capacidade de inferência indutiva sobre os classificadores *Naive Bayes* e *Adaboost* e por fim, por ser desenvolvida sobre a *framework scikit-learn*, uma importante *framework open-source* de *Machine Learning* fortemente utilizada no desenvolvimeto de aplicação (PEDREGOSA et al., 2011).

Na Subseção 3.3 e explicado o uso da abordagem *bag-of-words*, apesar de inúmeras configurações possíveis sobre este método, o mesmo foi utilizado em sua forma canônica, por fim, o objetivo era de não interferir na assinatura do padrão encontrado no texto.

Conforme foi explicado na [Subseção 3.4](#) na validação cruzada, o *dataset* balanceado foi dividido em dez partes iguais. Em teste anteriores foi observado, que devido a um número limitado de textos no *dataset*, a quantidade superior a dez partições não influenciava diretamente os resultados das métricas de desempenho, entretanto onerava consideravelmente o tempo de inferência indutiva dos classificadores.

6. Conclusão

Este trabalho teve por objetivo o estudo da recuperação de padrões na valoração textual de redações através da classificação de textos. Foram realizadas extensas avaliações sobre os algoritmos classificadores *Naive Bayes* e *Adaboost* no decorrer das atividades desenvolvidas para atingir os objetivos propostos. O classificador *Adaboost* não apresentou um resultado tão bom quanto o observado no *Naive Bayes*, mais nenhum momento deu-se o propósito de demonstrar superioridade de um algoritmo e relação ao outro, mas sim, atestar a legitimidade da hipótese proposta e demonstrar que ambos os algoritmos quando induzidos corretamente encontraria um padrão implícito no texto referente a cada competência induzida no classificador.

Após os métodos probabilísticos, o melhor resultado está associado ao classificador *Naive Bayes*, portanto, considero um forte aliado para recuperação de padrões na valoração textual.

Para trabalhos futuros pretende-se estudar e aperfeiçoar as técnicas de pré-processamento e extração de atributos com o objetivo de mensurar com maior representatividade o padrão encontrado dentro do texto, obtendo uma melhor separação entre as valorações de competências.

Referências

- BATISTA, G. et al. Aplicando seleção unilateral em conjuntos de exemplos desbalanceados: Resultados iniciais. In: *XIX CONGRESSO NACIONAL DA SOCIEDADE BRASILEIRA DE COMPUTAÇÃO “EDUCAÇÃO E APRENDIZAGEM NA SOCIEDADE DA INFORMAÇÃO*. [S.l.: s.n.], 1999. v. 20, p. 327–340. Citado na página [2](#).
- BOSCARIOLI, C.; VITERBO, J.; TEIXEIRA, M. F. Avaliação de aspectos de usabilidade em ferramentas para mineração de dados. *Anais da I Escola Regional de Sistemas de Informação do Rio de Janeiro*, v. 1, n. 1, p. 107–114, 2014. Citado na página [4](#).
- BRAGA, B. M. d. A. *Teoria da resposta ao item: o uso do modelo de Samejima como proposta de correção para itens discursivos*. Dissertação (Mestrado) — Universidade de Brasília Instituto de Ciências Exatas Departamento de matemática, 7 2015. Online; acessado 06 Junho 2017. Citado na página [3](#).
- BRITO, E. M. N. D. Mineração de textos: detecção automática de sentimentos em comentários nas mídias sociais. *Projetos e Dissertações em Sistemas de Informação e Gestão do Conhecimento*, v. 6, n. 1, 2017. Citado na página [4](#).
- CHAKRABARTI, S. *Mining the Web: Discovering knowledge from hypertext data*. [S.l.]: Elsevier, 2002. Citado na página [5](#).
- CSF, C. s. F. *Estudante de Graduação*. 2017. Online; acessado 07 Abril 2017. Disponível em: <http://www.cienciasemfronteiras.gov.br/web/csf/estudante>. Citado na página [2](#).

DEMŠAR, J. et al. Orange: Data mining toolbox in python. *Journal of Machine Learning Research*, v. 14, p. 2349–2353, 2013. Disponível em: <http://jmlr.org/papers/v14/demsar13a.html>. Citado na página 4.

ESCOLA, B. *Banco de redações*. 2017. Online; acessado 04 Setembro 2017. Disponível em: <http://vestibular.brasile scola.uol.com.br/banco-de-redacoes/>. Citado na página 5.

FERREIRA, L. P. C.; DOSCIATTI, M. M.; PARAISO, E. C. Estudo do impacto de um corpus desbalanceado na identificação de emoções em textos. p. 3, 2014. Disponível em: <https://www.researchgate.net/publication/277813458>. Citado na página 6.

INEP. Edital anual do exame nacional do ensino médio, *EDITAL No 10, DE 14 DE ABRIL DE 2016*. 2016. Online; acessado 05 Junho 2017. Disponível em: http://download.inep.gov.br/educacao_basica/enem/edital/2016/edital_enem_2016.pdf. Citado 3 vezes nas páginas 2, 3 e 8.

LARA, G. M. P. A redação como tema de pesquisa. In: *Leitura: Teoria e Prática*. [S.l.]: 1994, 1994. v. 13, n. 24, p. 62–82. Citado na página 1.

MACHADO, E. L. Um estudo de limpeza em base de dados desbalanceada e com sobreposição de classes. p. 19, 2009. Online; acessado 09 Setembro 2017. Disponível em: <http://repositorio.unb.br/handle/10482/1397>. Citado na página 6.

MATSUBARA, E. T.; MARTINS, C. A.; MONARD, M. C. Pretext: Uma ferramenta para pré-processamento de textos utilizando a abordagem bag-of-words. *Technical Report*, v. 209, 2003. Citado 2 vezes nas páginas 4 e 7.

MONARD, M. C.; BARANAUSKAS, J. A. Conceitos sobre aprendizado de máquina. *Sistemas Inteligentes-Fundamentos e Aplicações*, v. 1, n. 1, 2003. Citado na página 3.

MOTTA, P. R. d. A. *Estudo Exploratório do Uso de Classificadores para a Predição de Desempenho e Abandono em Universidades*. Dissertação (Mestrado) — Universidade Federal de Goiás Instituto de Informática, 11 2016. Online; acessado 06 Junho 2017. Citado na página 3.

NEGNEVITSKY, M. *Artificial intelligence: a guide to intelligent systems*. [S.l.]: Pearson Education, 2005. Citado na página 2.

ORANGE, D. M. *Orange Visual Programming*. 2017. Online; acessado 07 Setembro 2017. Disponível em: <https://docs.orange.biolab.si/3/visual-programming/>. Citado na página 6.

PEDREGOSA, F. et al. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011. Citado na página 11.

REIS, W. A. D. dos. Detecção de sinais de trânsito através do método de classificação adaboost. *UNOPAR Científica Ciências Exatas e Tecnológicas*, v. 12, n. 1, p. 28, 2015. Citado na página 5.

SCRAPY. *Scrapy*. 2017. Online; acessado 04 Setembro 2017. Disponível em: <https://scrapy.org/>. Citado na página 5.

SILVA, S. R. da; CARVALHO, T. L. Produção de texto escrito no ensino médio: Competências requeridas pela avaliação de redação do enem em (des)uso no livro didático de português. *Caminhos em linguística aplicada*, 1o sem 2017, v. 16, n. 1, p. 1–25,

2017. Disponível em: <http://periodicos.unitau.br/ojs-2.2/index.php/caminhoslinguistica>. Citado na página 3.

SISU, S. d. s. u. *O que é o Sisu*. 2017. Online; acessado 07 Abril 2017. Disponível em: <http://sisu.mec.gov.br/>. Citado na página 2.

TAVARES, L. G.; LOPES, H. S.; LIMA, C. R. E. Estudo comparativo de métodos de aprendizado de máquina na detecção de regiões promotoras de genes de escherichia coli. *Anais do I Simpósio Brasileiro de Inteligência Computacional*, p. 8–11, 2007. Citado na página 7.

UOL. *Banco de redações*. 2017. Online; acessado 01 Junho 2017. Disponível em: <https://educacao.uol.com.br/bancoderedacoes/>. Citado na página 5.

WAHBEH, A. H. et al. A comparison study between data mining tools over some classification methods. *International Journal of Advanced Computer Science and Applications*, v. 8, n. 2, p. 18–26, 2011. Citado 2 vezes nas páginas 4 e 6.

WAYMO. *We're building a safer driver for everyone*. 2017. Online; acessado 07 Abril 2017. Disponível em: <https://waymo.com/>. Citado na página 2.